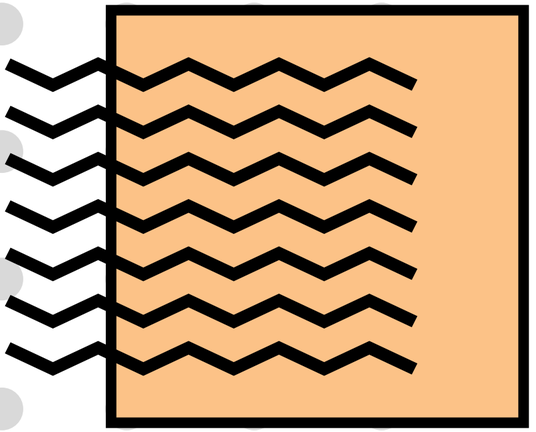
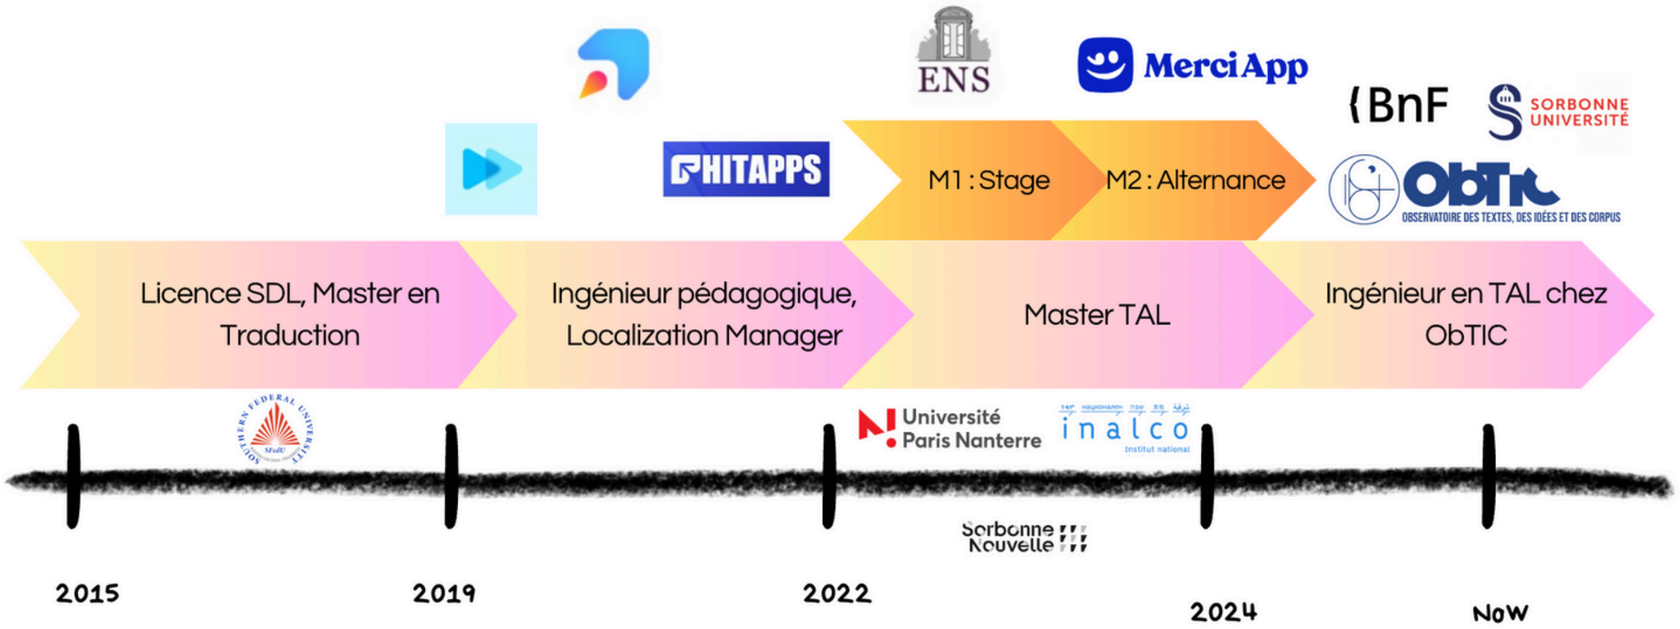


PROMPT ENGINEERING : L'ART DES REQUÊTES EFFICACES

Préparé par : Mikhail Biriuchhinskii
Ingénieur en Traitement automatique des langues
ObTIC

MON PARCOURS





Mikhail Biriuchinskii (He/Him)

NLP Engineer | Data Scientist

Paris, Île-de-France, France · **Contact info**

500+ connections

Au cas où, voici ma page Linkedin.

PLAN DE RÉUNION

01

THÉORIE : BASES

Les notions de base de Prompt engineering

02

PROMPTING TECHNICS

Revue des techniques emblématiques

03

PROJET CV

Série d’exercices sur un document distribué

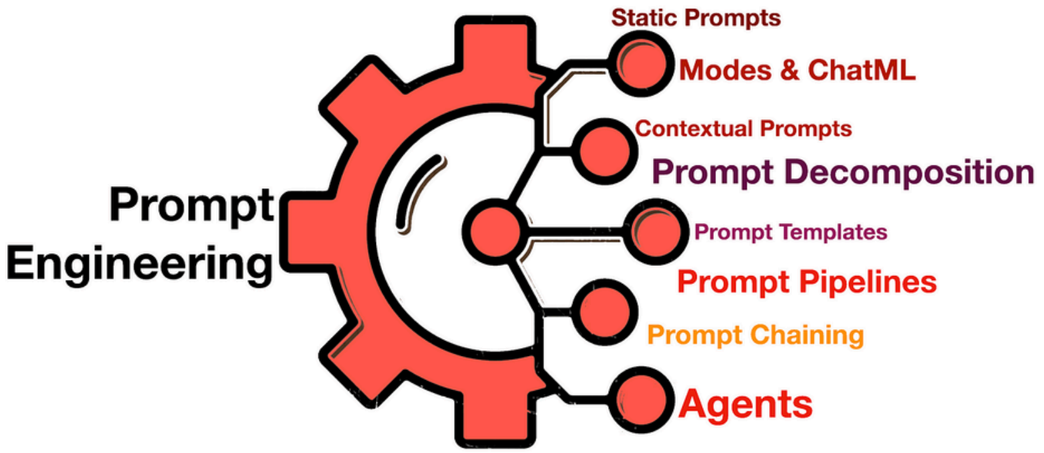
04

BONUS

Si le temps le permet

INTRODUCTION : OBJECTIFS DE L'ATELIER

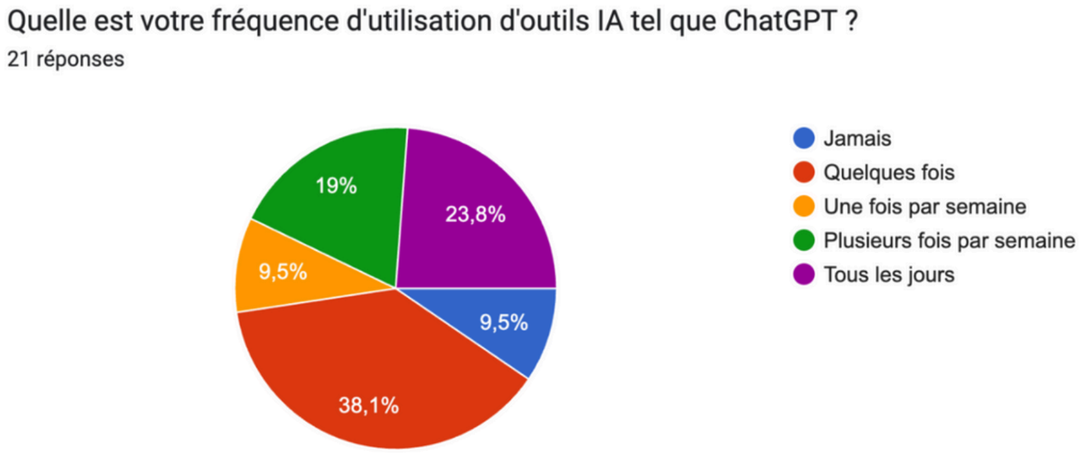
- Comprendre les concepts de base de Prompt Engineering (no code !)
- Acquérir les bonnes pratiques
- Mettre en œuvre les concepts appris



INTRODUCTION

D’après directeur général de la société OpenAI Sam Altman :

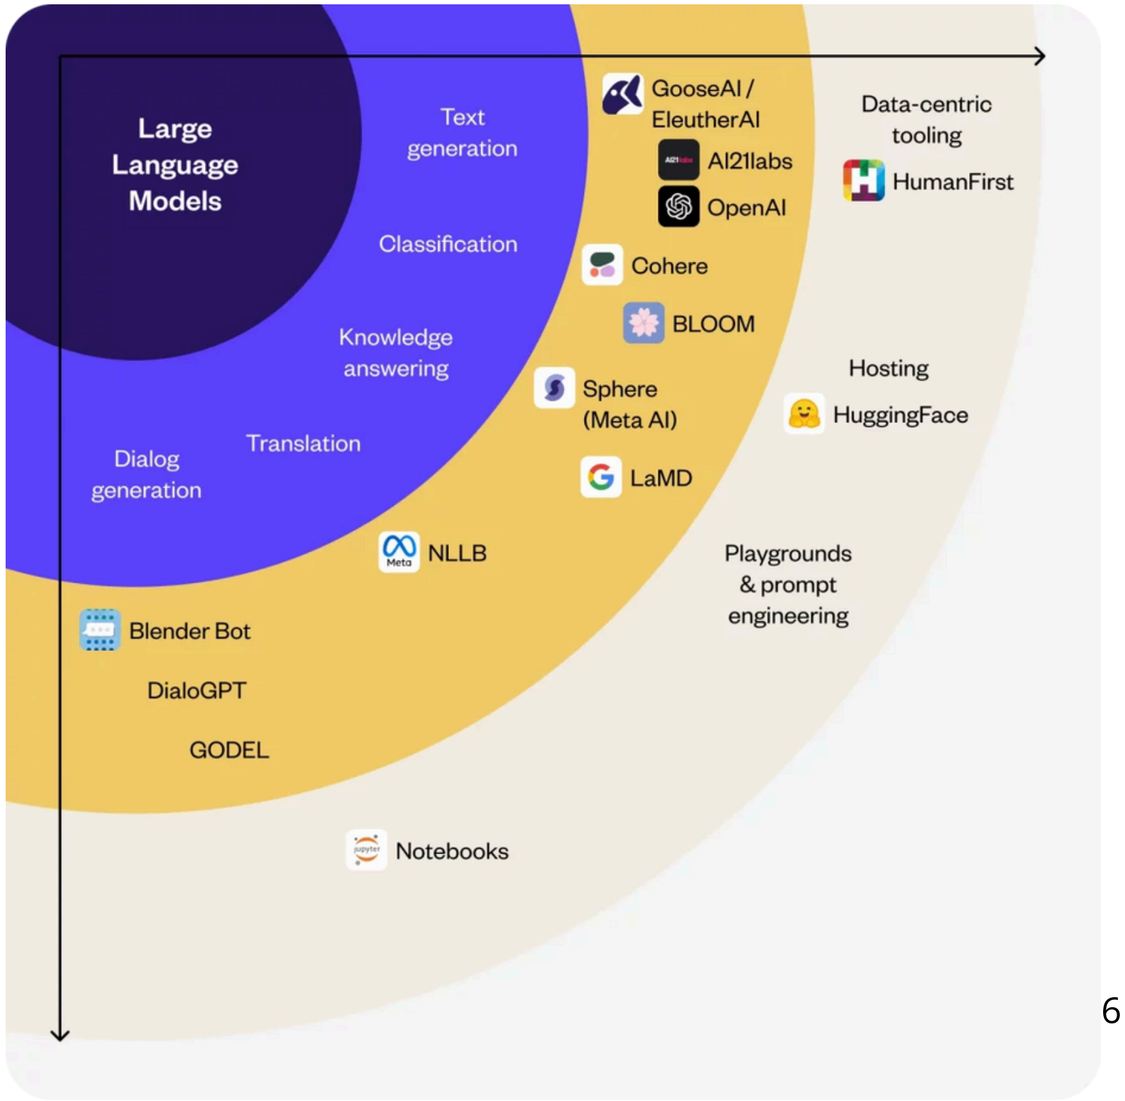
*En moins d’un an, ChatGPT a atteint **100 millions d’utilisateurs hebdomadaires**, et plus de 2 millions de développeurs utilisent actuellement l’API de l’entreprise, y compris la majorité des entreprises du Fortune 500.*



OpenAI

THÉORIE : GRAND MODÈLE DE LANGAGE (LLM)

Un **Large Language Model** (LLM) est une forme d'intelligence artificielle conçue pour comprendre et générer du langage naturel, similaire à la manière dont les humains communiquent.



THÉORIE : DEUX TYPES DE GRAND MODÈLE DE LANGAGE (LLM)

Base LLM

Prédiction des mots basée sur les données d'entrainement
(ex: meta-llama/Llama-3.2-3B)

Tu t'appelles comment ? The French have a saying: "Tu t'appelles comment?" which means "You call yourself what?" It's a way of asking someone what their name is.

Instruction-tuned LLM

Suivi des instructions + prédiction des mots
(ex: meta-llama/Llama-3.2-3B-Instruct

Tu t'appelles comment ? Je suis un modèle d'intelligence artificielle connu sous le nom de Llama. Llama est l'abréviation de "Large Language Model Meta AI".

Comment reconnaître ? - 'IT', 'Instruct' ou 'Chat' dans le nom !

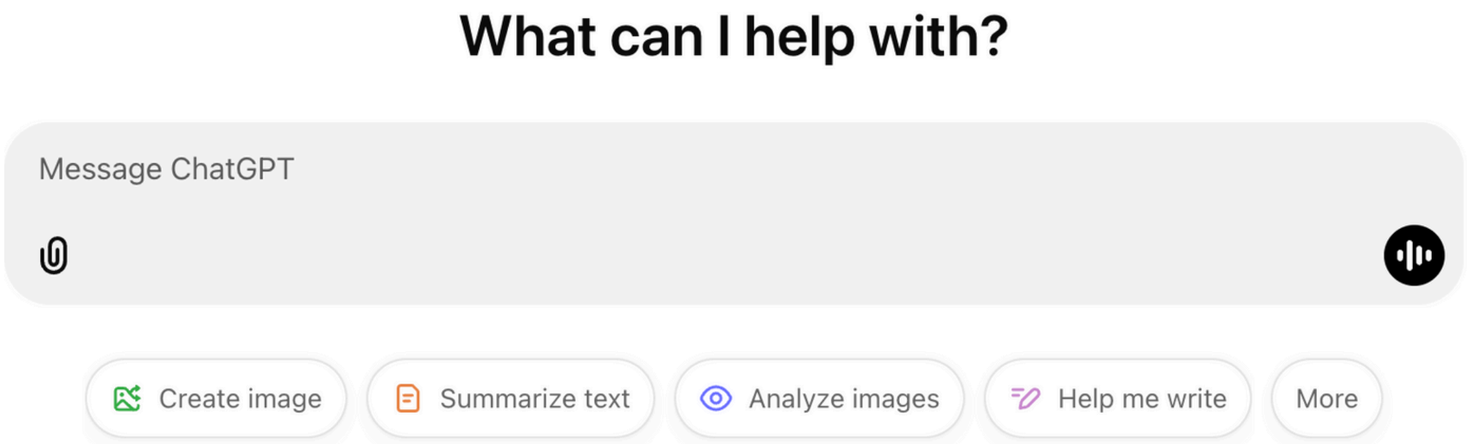
Chatbots

THÉORIE : CHATBOT LLMS

Chatbot LLMs - produits tout prêts pour l'utilisation de LLM. Interface conviviale, sans besoin de coder.

GPT-4o (+ mini) : Version limitée | gratuite, permet l'accès au web, l'analyse d'images et de données, génération d’images, conversation avec une IA

https://chatgpt.com/



THÉORIE : CHATBOT LLMS

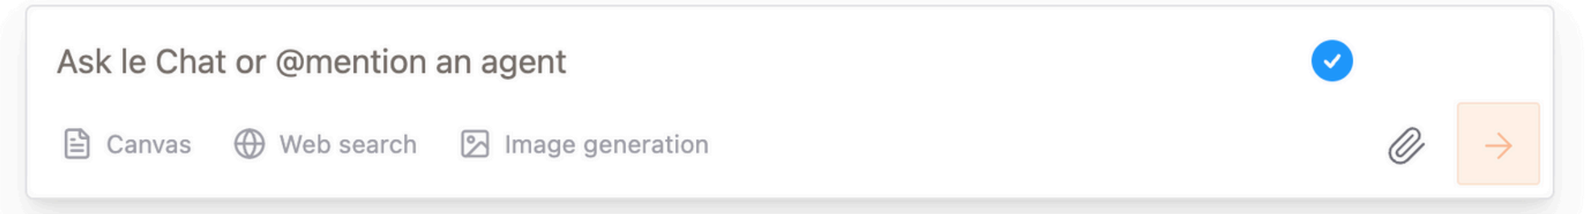
Chatbot LLMs - produits tout prêts pour l'utilisation de LLM. Interface conviviale, sans besoin de coder.

Mistral le Chat : Gratuit et en version bêta.

Recherche web, Analyse de documents complexes (PDF, graphiques, tableaux), Génération d'images

LE CHAT
MISTRAL_

https://chat.mistral.ai



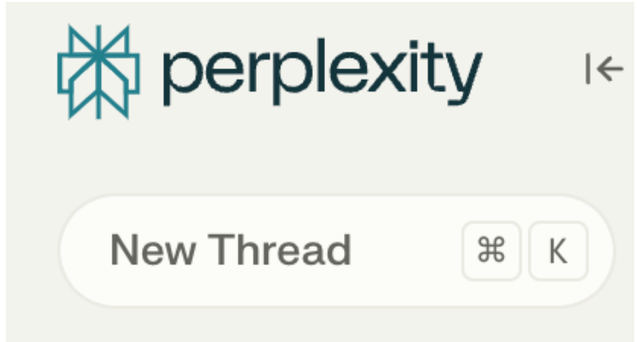
THÉORIE : CHATBOT LLMS

Chatbot LLMs - produits tout prêts pour l'utilisation de LLM. Interface conviviale, sans besoin de coder.

Perplexity : Gratuit avec option payante.

Recherche web en temps réel, Réponses accompagnées avec des citations, Exploration approfondie des sujets, Section Q&A

https://www.perplexity.ai/



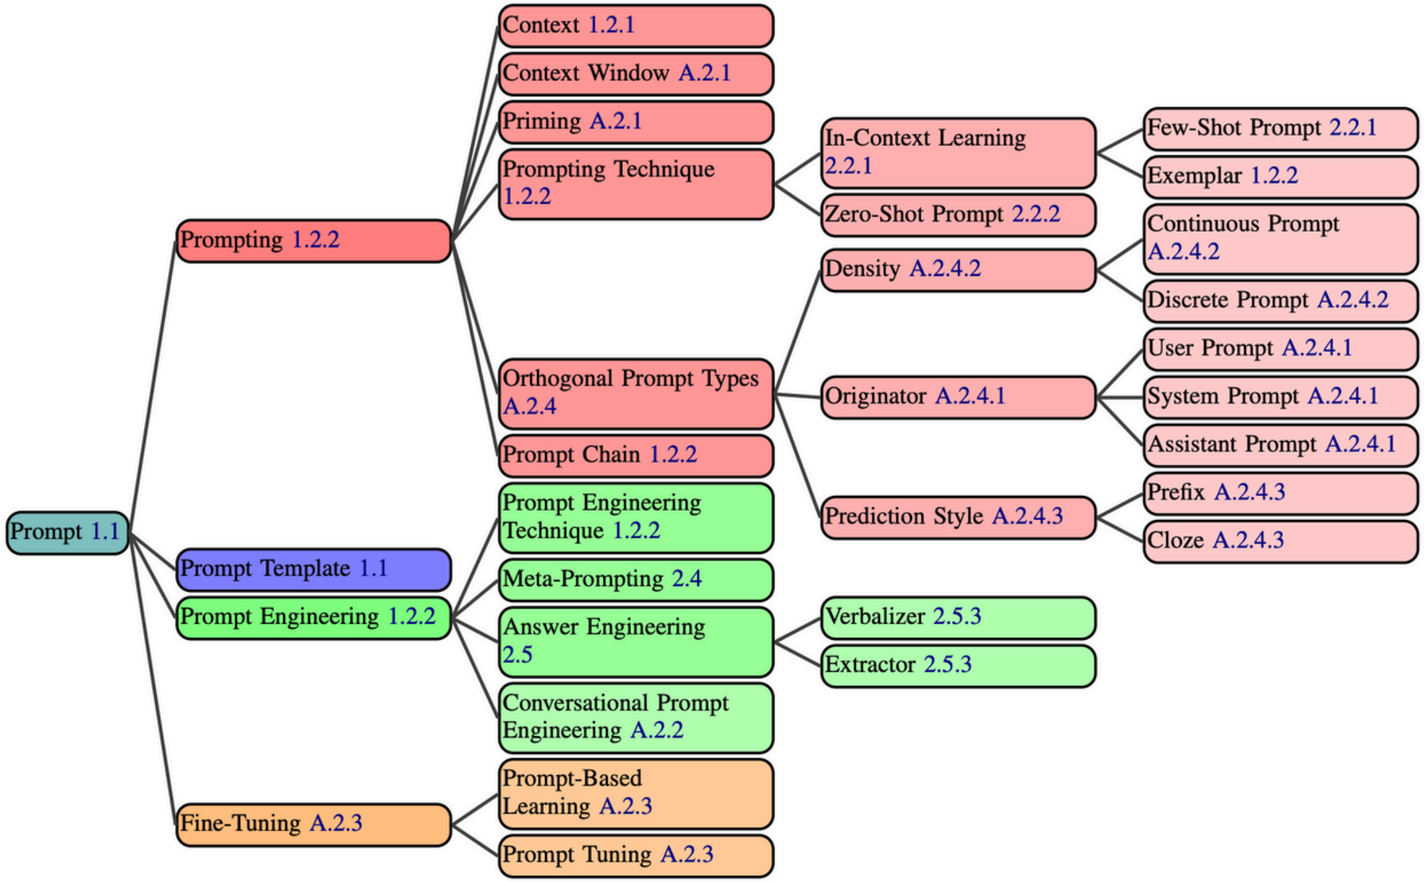
THÉORIE : QU'EST-CE QU'UN PROMPT ?

Prompt (requête) : Un contexte textuel fourni aux modèles de langage afin d'orienter leurs prédictions du texte pertinent en fonction de l'objectif visé.

> Je n'ai pas aimé le service qui m'a été fourni lorsque je suis entré dans l'hôtel. Je n'ai pas non plus aimé le quartier dans lequel l'hôtel était situé. Il y avait trop de bruit et d'événements pour que je me sente à l'aise. En résumé, notre séjour a été décevant ... (Base LLM)

Le **prompt engineering** est une discipline relativement nouvelle pour développer et optimiser des prompts afin d'utiliser efficacement des LLMs pour une *grande variété d'applications*.

THÉORIE : TOUT SAVOIR ?



Schulhoff, S., Ilie, M., Balepur, N., Kahadze, K., Liu, A., Si, C., ... & Resnik, P. (2024).
The Prompt Report: A Systematic Survey of Prompting Techniques.
arXiv preprint arXiv:2406.06608.

THÉORIE : PARAMÈTRES LLM

Temperature - est un paramètre qui contrôle le caractère aléatoire de la sélection des mots lors de la création du texte.

0 (prédictible) - 1+ (aléatoire)

Top_p - est un paramètre qui détermine le nombre de mots possibles à prendre en compte.

0 (prédictible) - 1 (aléatoire)

La recommandation générale est de modifier l'un ou l'autre, mais pas les deux.

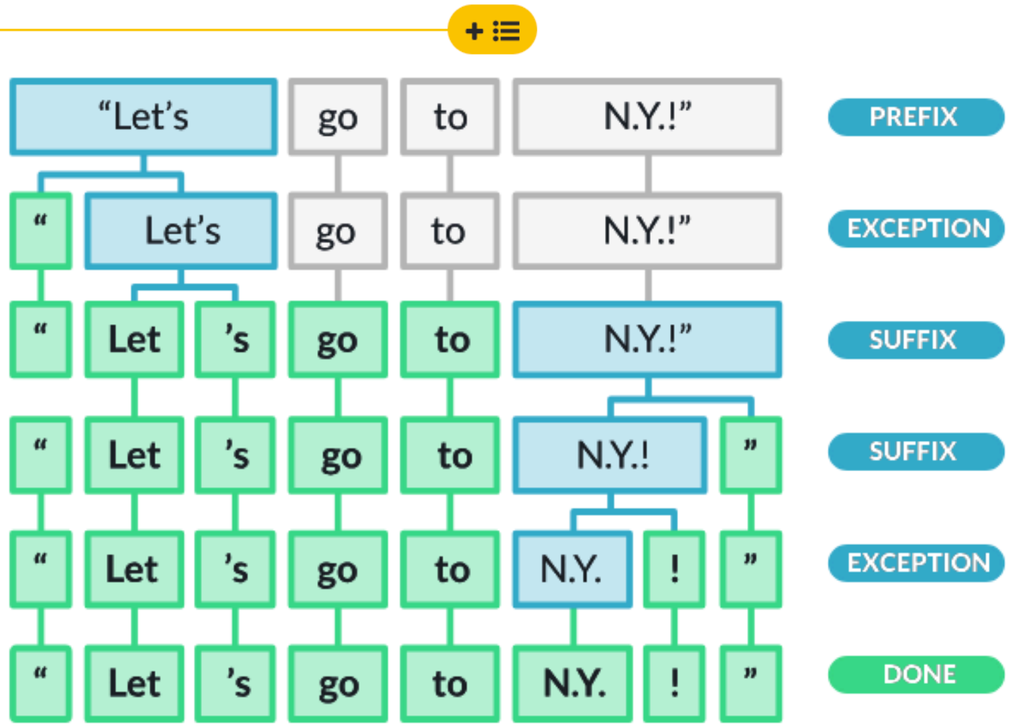
THÉORIE : PARAMÈTRES LLM

Token - séquences fréquentes de caractères trouvées dans un texte

token *noun* [C] (LANGUAGE)

LANGUAGE • specialized

a unit of language that is used in a particular text :



Exemple de tokénization de module SpaCy

THÉORIE : PARAMÈTRES LLM

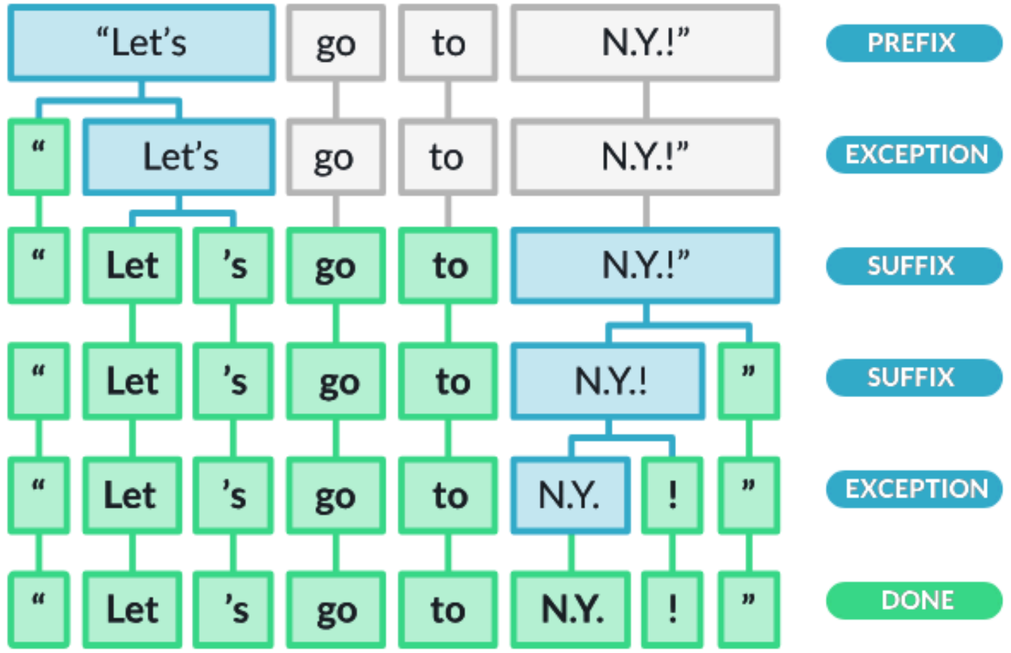
Token - séquences fréquentes de caractères trouvées dans un texte

token *noun* [C] (LANGUAGE)

LANGUAGE • specialized

a unit of language that is used in a particular text :

‘Pomme de terre’ - 1 token ou 3 ?



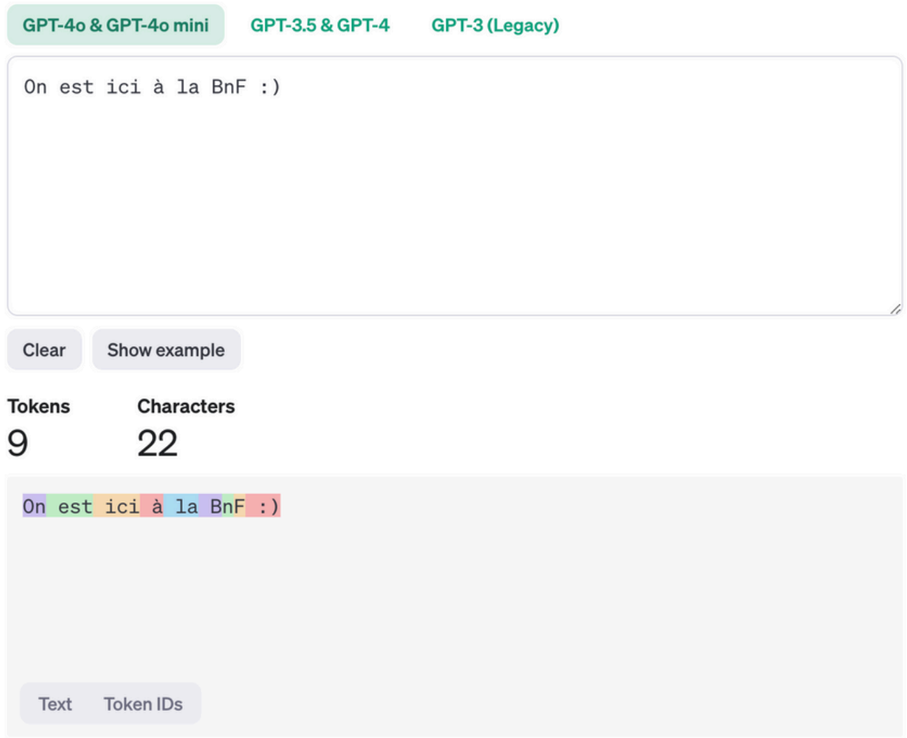
Exemple de tokénization de module SpaCy

THÉORIE : PARAMÈTRES LLM

Max Length / Tokens - le paramètre pour gérer le nombre de tokens générés par le modèle en ajustant la longueur maximale.

Quand utiliser Max_Tokens ?

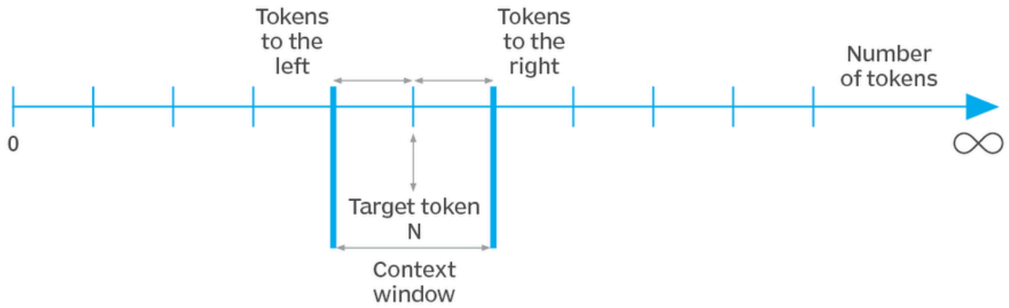
- Pour les réponses de chat
- Comme mesure de sécurité
- Optimiser le temps de traitement



THÉORIE : PARAMÈTRES LLM

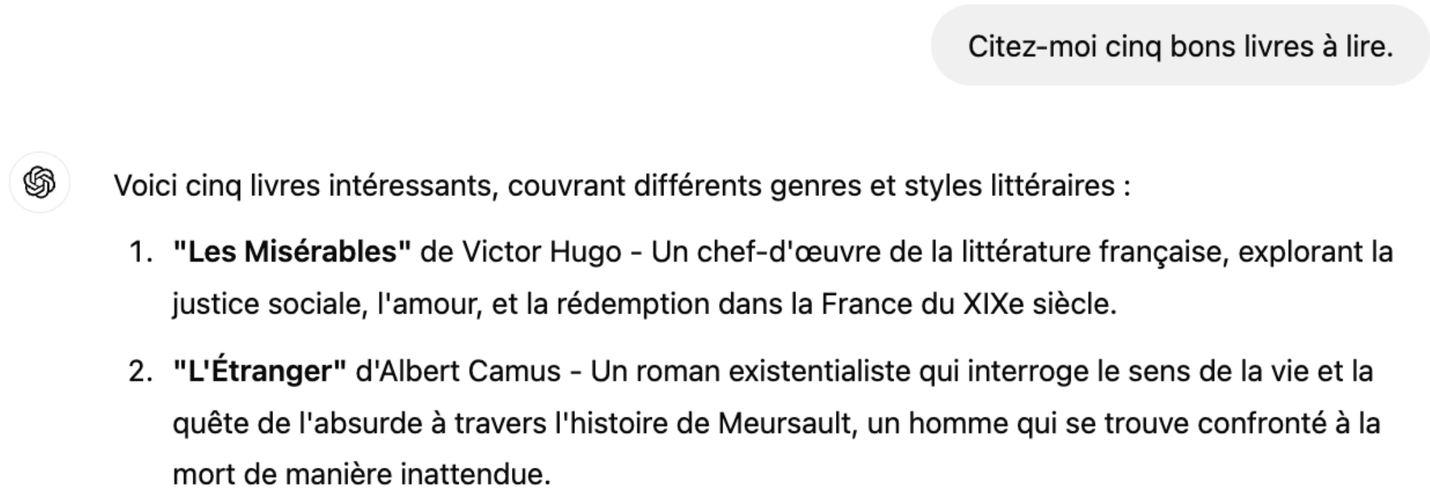
Context window - la quantité de données textuelles qu'un LLM peut prendre en compte en même temps pour générer des réponses.

MODEL	DESCRIPTION	CONTEXT WINDOW	MAX OUTPUT TOKENS	TRAINING DATA
gpt-4o	**GPT-4o**: Our high-intelligence flagship model for complex, multi-step tasks. GPT-4o is cheaper and faster than GPT-4 Turbo. Currently points to gpt-4o-2024-05-13 [1].	128,000 tokens	4,096 tokens	Up to Oct 2023
gpt-4o-2024-05-13	gpt-4o currently points to this version.	128,000 tokens	4,096 tokens	Up to Oct 2023
gpt-4o-2024-08-06	Latest snapshot that supports Structured Outputs	128,000 tokens	16,384 tokens	Up to Oct 2023
chatgpt-4o-latest	Dynamic model continuously updated to the current version of GPT-4o in ChatGPT. Intended for research and evaluation [2].	128,000 tokens	16,384 tokens	Up to Oct 2023



THÉORIE : LES COMPOSANTES D'UN PROMPT

Instruction (Directive) - une tâche ou une instruction spécifique que vous souhaitez que le modèle exécute.



Contexte - peut impliquer des informations externes ou un contexte supplémentaire qui peut orienter le modèle vers de meilleures réponses.

--> J'ai 9 ans.

THÉORIE : LES COMPOSANTES D'UN PROMPT

Input Data - est l'entrée ou la question pour laquelle nous souhaitons trouver une réponse.
--> Traduis en français : 'Hello world'

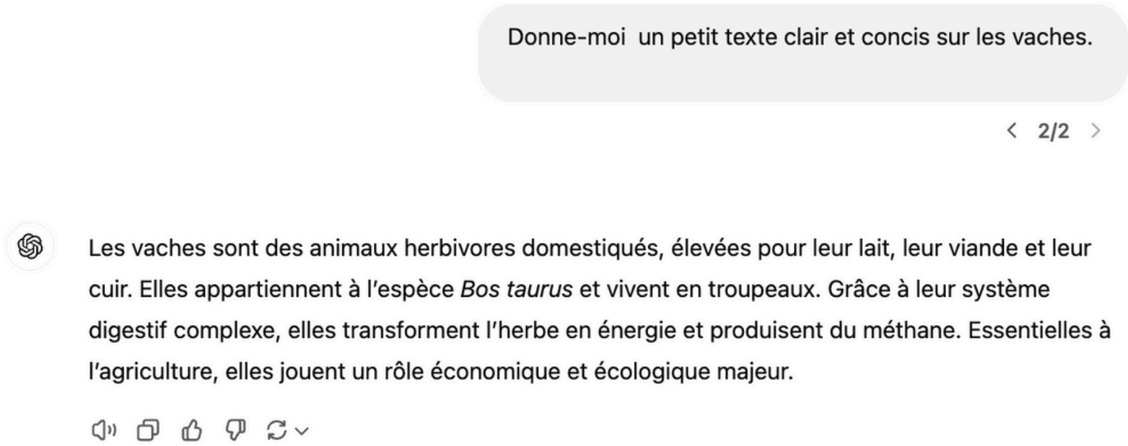
Exemples (shots) - des démonstrations qui guident la GenAI à accomplir une tâche.

---> Night: Noche
Morning:

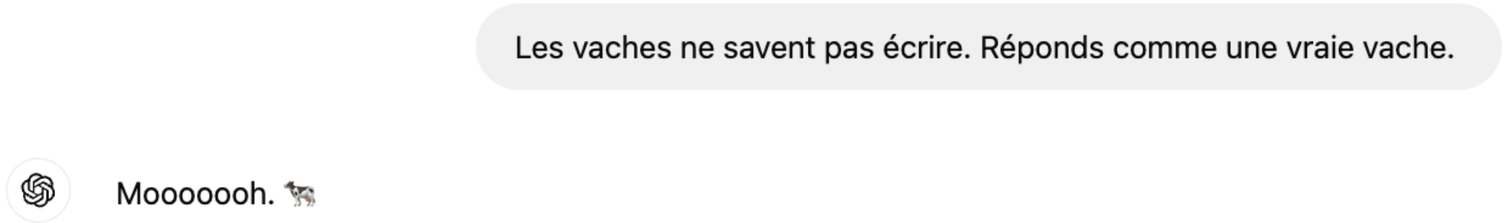
Output Indicator - indique le type ou le format de la sortie.
--> Quels sont les mots les plus récents du français moderne ? Renvoie-moi le texte au format ___.

THÉORIE : LES COMPOSANTES D'UN PROMPT

Style instructions - le formatage utilisé pour modifier le résultat stylistiquement.



Rôle (persona) - on demande au modèle de jouer le rôle d'un caractère fictif.



CLAUDE : STRUCTURE RECOMMANDÉE POUR UN PROMPT

Task context :

Tu es un assistant virtuel qui aide les utilisateurs à trouver des informations sur les produits.

Tone context :

Réponds de manière amicale et professionnelle.

Background data, documents, and images :

Voici le site (lien) où tu te trouves.

Detailed task description & rules :

Utilise les informations du site pour répondre. Ne donne pas d'infos non confirmées.

Examplars :

Utilisateur : Quelles sont les caractéristiques du produit X ?

Assistant : Le produit X a une capacité de 500 Go et une vitesse de 1 To/s.

Directive :

L'utilisateur pose une question sur les caractéristiques d'un produit.

Output formatting :

Renvoie le texte brut.

THÉORIE : COSTAR METHODOLOGY

Contexte (C) :

- Je suis un développeur de productivité personnelle.

Objectif (O) :

- Guider dans la création d'un système de conversion de objectifs.

Style (S) :

- Écrire de manière claire et structurée, comme un guide.

Ton (T) :

- Maintenir un ton positif et motivant.

Audience (A) :

- Public intéressé par le développement personnel et la productivité.

Réponse (R) :

- Fournir une liste structurée des étapes.

Verbes à utiliser	Verbes à éviter
Écrire	Comprendre
Compléter	Penser
Expliquer	Estimer
Décrire	Essayer
Évaluer	Savoir
...	...

THÉORIE : CONSEILS GÉNÉRAUX POUR LA CONCEPTION DES PROMPTS

Simplicité : Commencez simplement

- Utilisez des verbes d'action / impératifs

Extrais le nom des lieux dans le texte suivant.
Format voulu :
Place : <comma_separated_list_of_places>
Input : "Le Krémlin, centre du pouvoir russe, a longtemps influencé les relations internationales. À des milliers de kilomètres, l'Hexagone, terre des Gaulois, voit des débats sur sa place dans l'Europe contemporaine. Pendant ce temps, Paris, capitale emblématique, reste le cœur politique et culturel du pays."

THÉORIE : CONSEILS GÉNÉRAUX POUR LA CONCEPTION DES PROMPTS

Spécificité : Soyez précis

- Évitez les imprécisions
- Comprenez bien ce que vous voulez obtenir

Extrais les entités nommées des lieux dans le texte suivant (entités localisées géographiquement).
Format voulu :
Place : <comma_separated_list_of_places>
Input : "Le Krémlin, centre du pouvoir russe, a longtemps influencé les relations internationales. À des milliers de kilomètres, l'Hexagone, terre des Gaulois, voit des débats sur sa place dans l'Europe contemporaine. Pendant ce temps, Paris, capitale emblématique, reste le cœur politique et culturel du pays."

2 Place : Krémlin, Russie, Hexagone, Europe, Paris

1 Place : Krémlin, Hexagone, Paris

THÉORIE : MÉTRIQUES ET MÉTHODES D'ÉVALUATION

Métriques quantitatives :

- Spécifiques à la tâche : score F1, score BLEU, perplexité
- Génériques : précision, rappel, exactitude
- Opérationnelles : temps de réponse (ms)

Méthodes quantitatives :

- Test A/B : Comparer les performances à un modèle de référence ou une version antérieure.
- Retour utilisateur : Mesures implicites, comme les taux de réussite des tâches.

Échelles qualitatives :

- Échelles de Likert : « Évaluez la cohérence de 1 (absurde) à 5 (parfaitement logique) »
- Grilles d'évaluation d'experts : Linguistes évaluant la qualité des traductions selon des critères définis.

THÉORIE : À VOUS DE JOUER

But : obtenir une définition de ‘prompt’ qui décrit le concept de manière la plus générale possible.

Quel prompt répond mieux à cette tâche ?

Donne-moi une définition du mot anglais 'prompt'.

Donne-moi une définition de 'prompt'.



THÉORIE : À VOUS DE JOUER

But : obtenir une définition de ‘prompt’ qui décrit le concept de manière la plus générale possible.

Quel prompt répond mieux à cette tâche ?

Donne-moi une définition du mot anglais 'prompt'.

2/2

Le mot anglais *prompt* a plusieurs significations, mais en général, il désigne quelque chose qui incite ou pousse à une action. Voici les principales définitions :

1. **Nom** : Une incitation ou un stimulus qui déclenche une réaction, une réponse ou une action. Par exemple, dans le contexte informatique, un *prompt* peut être une invite de commande ou une instruction.
2. **Verbe** : Pousser quelqu'un à faire quelque chose ou l'amener à réagir. Par exemple, "The teacher prompted the student to answer."
3. **Adjectif** : Qui est rapide ou immédiat, comme dans "a prompt response" (une réponse rapide).

Le sens dépend du contexte dans lequel il est utilisé.

Donne-moi une définition de 'prompt'.

Un *prompt* (ou "invite" en français) dans le contexte de l'intelligence artificielle désigne l'entrée ou la requête donnée à un modèle de langage pour générer une réponse. Il s'agit généralement d'un texte qui guide le modèle pour produire une sortie souhaitée. Le prompt peut être une question, une instruction, ou même un fragment de texte, selon ce que l'on attend de la réponse du modèle.

THÉORIE : À VOUS DE JOUER

But : rédiger un résumé concis d'un article scientifique.

Quel prompt répond mieux à cette tâche ?

Résume cet article scientifique.

Résume cet article scientifique en 3 à 5 phrases, en mettant l'accent sur les objectifs de recherche, la méthodologie et les résultats principaux.





THÉORIE : MULTIPLES SECTIONS DANS UN PROMPT

But : vérifier l'orthographe de l'instruction du prompt.

Quel prompt répond mieux à cette tâche ?

Corrige l'instruction de mon prompt
I will give you the texte and the task. Then, you will think about this task and execut it.
Your task consist to extract the named entitie (NER) from the provided texte.
Here is the texte:
Pandan peryòd esè 7-mwa a, fanm lan te tonbe soti nan jijman an paske yo te laktasyon diminye konpare ak okenn nan gwoup la IUD.

Prompt 1

Instruction

Contexte

Input données

Corrige l'instruction de mon prompt délimité par triples """.
Prompt : """ I will give you the texte and the task. Then, you will think about this task and execut it.
Your task consist to extract the named entitie (NER) from the provided texte.
Here is the texte: """ Pandan peryòd esè 7-mwa a, fanm lan te tonbe soti nan jijman an paske yo te laktasyon diminye konpare ak okenn nan gwoup la IUD.

Prompt 2

THÉORIE : MULTIPLES SECTIONS DANS UN PROMPT

But : vérifier l'orthographe de l'instruction du prompt.

Quel prompt répond mieux à cette tâche ?

Bien sûr, voici la version corrigée de votre instruction :

Je vais vous donner le texte et la tâche. Ensuite, vous réfléchirez à cette tâche et l'exécuterez.

Votre tâche consiste à extraire les entités nommées (NER) du texte fourni.

Voici le texte :

Pendant la période d'essai de 7 mois, la femme est tombée hors du jugement car ils étaient en lactation diminuée comparée à n'importe quel groupe IUD.

Prompt 1

Bien sûr, voici la version corrigée de votre prompt :

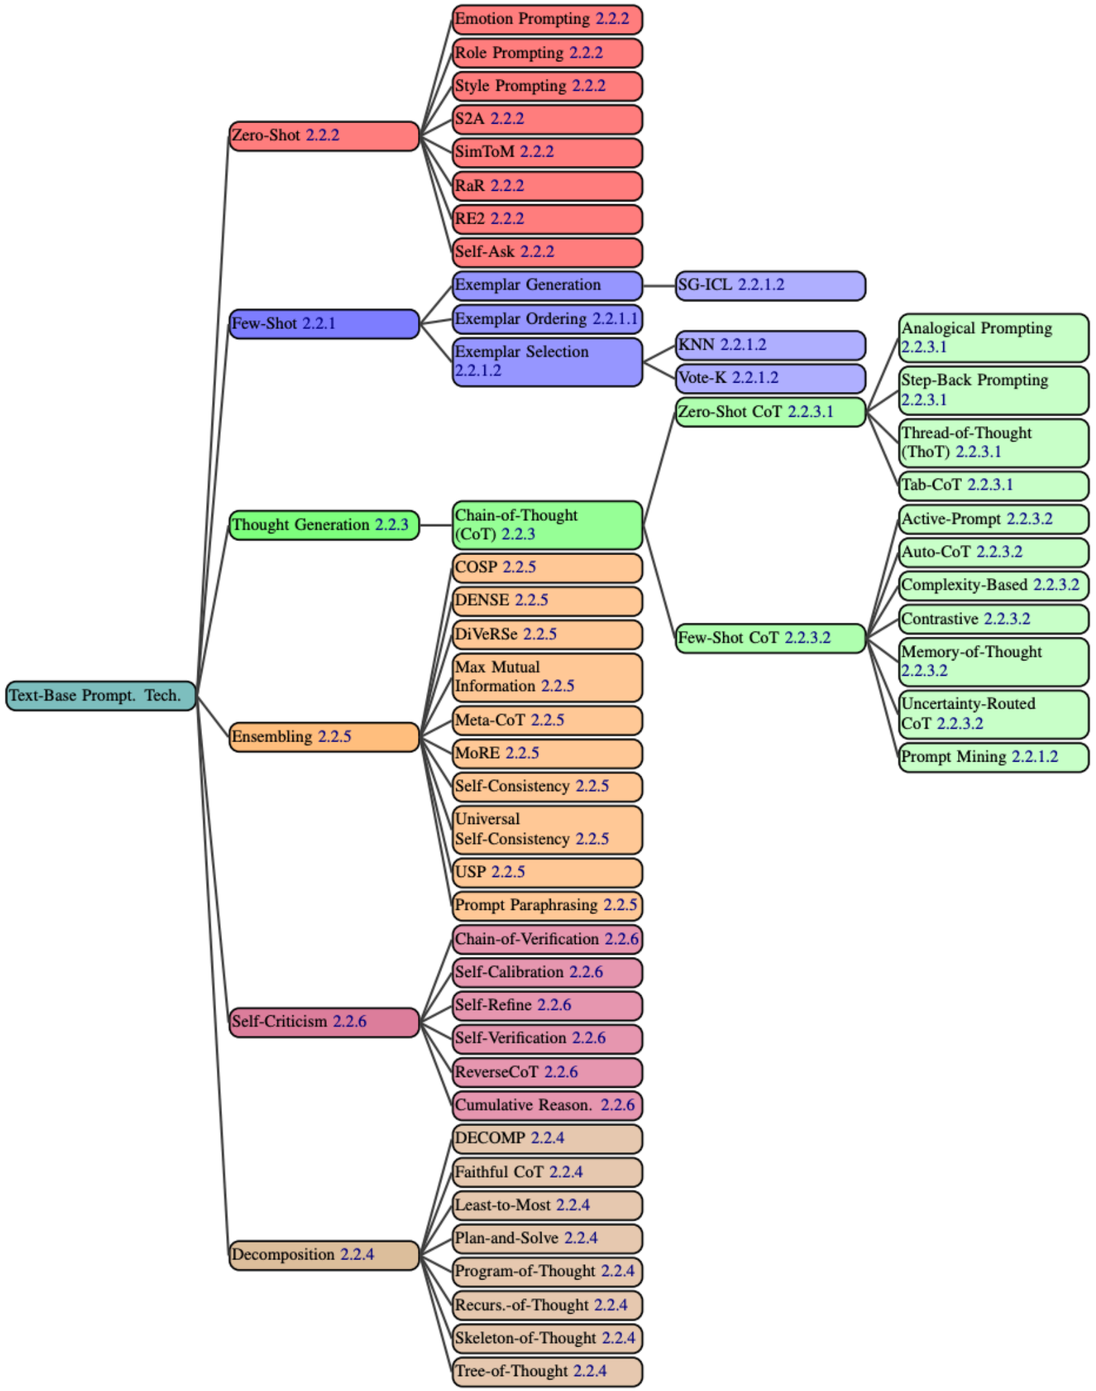
Prompt :
"""
I will give you the text and the task. Then, you will think about this task and execute it.

Your task consists of extracting the named entities (NER) from the provided text.

Here is the text:
"""
Pandan peryòd esè 7-mwa a, fanm lan te tonbe soti nan jijman an paske yo te laktasyon diminye konpare ak okenn nan gwoup la IUD.

Prompt 2

cf. : Du créole haitien : Au cours de la période d'essai du mois 7, la femme 1 s'est retirée de l'essai en raison d'une lactation réduite, comparativement à aucune chez le groupe DIU.



PROMPTING TECHNIQUES

TECHNIQUE : ZERO SHOT

Un **zero-shot prompting** est un prompt qui repose sur les connaissances générales du modèle et ne fournit aucun exemple de la manière dont la tâche doit être accomplie.

Analysez ce texte. Modèle, a-t-il suffisamment de connaissances pour effectuer cette tâche ?

Classez le texte en neutre, négatif ou positif.
Texte : Gnighty sheesh <(°v°<)(>°v°)>

Classement :



TECHNIQUE : FEW-SHOT

Le **few-shot prompting** consiste à inclure quelques exemples d'une tâche spécifique dans le prompt.

Analysez ce prompt. Modèle, a-t-il suffisamment de connaissances pour effectuer cette tâche ?

Classez le texte en neutre, négatif ou positif.

Exemples :
I checked the boxes : neutre
Stupid storm. No yachting for us today : négatif
Happy mother's day mumm !! xoxo :3 : positif

Texte : Gnighty sheesh <(°v°<)(>°v°)>

Classement :

TECHNIQUE : CHAIN OF THOUGHT

Le prompting en **chaîne de raisonnement** (CoT) est une approche qui améliore les capacités de raisonnement des LLMs en décomposant des questions ou des tâches complexes en étapes plus petites et plus gérables.

Je suis allé au marché et j'ai acheté 10 pommes. J'ai donné 2 pommes au voisin et 2 au dépanneur. Je suis ensuite allé acheter 5 pommes de plus et j'en ai mangé 1. Avec combien de pommes suis-je resté ?

RÉPONSE ATTENDUE : 10 POMMES

TECHNIQUE : COMBINAISONS

(a) Few-shot

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?
A: The answer is 11.

Q: A juggler can juggle 16 balls. Half of the balls are golf balls, and half of the golf balls are blue. How many blue golf balls are there?
A:

(Output) The answer is 8. ✗

(b) Few-shot-CoT

Q: Roger has 5 tennis balls. He buys 2 more cans of tennis balls. Each can has 3 tennis balls. How many tennis balls does he have now?
A: Roger started with 5 balls. 2 cans of 3 tennis balls each is 6 tennis balls. 5 + 6 = 11. The answer is 11.

Q: A juggler can juggle 16 balls. Half of the balls are golf balls, and half of the golf balls are blue. How many blue golf balls are there?
A:

(Output) The juggler can juggle 16 balls. Half of the balls are golf balls. So there are 16 / 2 = 8 golf balls. Half of the golf balls are blue. So there are 8 / 2 = 4 blue golf balls. The answer is 4. ✓

(c) Zero-shot

Q: A juggler can juggle 16 balls. Half of the balls are golf balls, and half of the golf balls are blue. How many blue golf balls are there?
A: The answer (arabic numerals) is

(Output) 8 ✗

(d) Zero-shot-CoT (Ours)

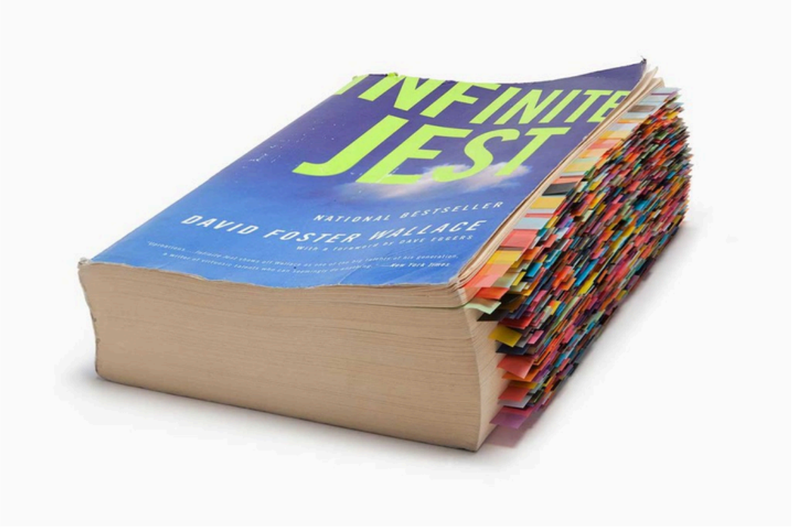
Q: A juggler can juggle 16 balls. Half of the balls are golf balls, and half of the golf balls are blue. How many blue golf balls are there?
A: ***Let's think step by step.***

(Output) There are 16 balls in total. Half of the balls are golf balls. That means that there are 8 golf balls. Half of the golf balls are blue. That means that there are 4 blue golf balls. ✓

Image Source: Kojima et al. (2022)

ATTENTION : HALLUCINATIONS

Utilisez le prompt. Est-ce possible d'éviter l'hallucination ? Changez-le pour voir.



Nous allons discuter du roman L'infinie comédie.

Ce livre raconte l'histoire de trois frères dont les personnalités sont similaires à celles d'un autre livre auquel il est fait référence dans l'histoire. Quel est ce livre ?

Dans *L'Infinie Comédie* (*Infinite Jest*) de David Foster Wallace, les trois frères Vossler sont souvent comparés aux personnages du roman *Les Frères Karamazov* de Fiodor Dostoïevski. L'œuvre de Dostoïevski est un thème récurrent dans *Infinite Jest*, avec les personnalités des frères Vossler rappelant celles des trois frères Karamazov : Dmitri, Ivan et Alexeï, chacun représentant différents aspects de l'humanité et des dilemmes philosophiques.

Dans *La Comédie Infinie* de l'auteur Thomas Clerc, les trois frères ont des personnalités qui rappellent celles des personnages du roman *Les Frères Karamazov* de Fiodor Dostoïevski. Dans le

PROJET CV

PROJET CV

Sacha n’en peut plus… elle a fait un burnout et elle a finalement quitté sa boîte.

On va l’aider à trouver une meilleure place grâce aux LLMs.

Faites une série d’exercices et présentez vos résultats.



Sacha Dubois

CHARGÉE DE PROJET ÉVÉNEMENTIEL

Professionnelle expérimentée dans la gestion événementielle avec une passion pour la planification et la réalisation d'événements mémorables. Solide expérience dans la coordination de projets, la budgétisation et la gestion des parties prenantes.
À la recherche d'opportunités pour mettre en œuvre ma créativité et mes compétences organisationnelles pour créer des expériences uniques.

COORDONNÉES

123-456-7890

hello@reallygreatsite.com

123 Anywhere St.,
Any City, ST 12345

@reallygreatsite

LANGUES

Anglais — Niveau business

Espagnol — Conversationnel

FORMATION

Licence en Gestion Événementielle
Université Événementielle,
Any City, Juin 2018

CENTRES D'INTÉRÊT

Voyages solo, photographie de rue, cuisine asiatique

EXPÉRIENCE PROFESSIONNELLE

Chargée de Projet Événementiel

ÉVÉNEMENTS EXTRAORDINAIRES, ANY CITY — Avril 2020 - Présent

- Orchestration de plus de 50 événements d'envergure (conférences, lancements de produits, soirées de gala), gérant jusqu'à 800 participants par événement.
- Direction de la gestion complète du cycle de projet : étude des besoins, conception thématique, planification des budgets (jusqu'à 500 000 €), coordination des fournisseurs et suivi post-événementiel.
- Mise en œuvre d'outils de gestion de projet (Trello, Asana) pour optimiser les processus et améliorer la collaboration interéquipe.
- Réduction des dépenses d'approvisionnement de 15 % grâce à des négociations stratégiques avec les fournisseurs.

Assistante Événementielle

ÉVÉNEMENTS MAJESTUEUX, ANY CITY — Juillet 2018 - Mars 2020

- Contribution à la réussite de plus de 30 mariages et galas de bienfaisance, accueillant en moyenne 300 à 500 invités.
- Coordination des inscriptions des participants via des outils CRM (Salesforce), gérant des bases de données de plus de 2 000 contacts.
- Supervision des fournisseurs et résolution de problèmes en temps réel pour assurer une expérience client exceptionnelle.

RÉALISATIONS

- Lancement de produit Fortune 500 : Organisation d'un événement phare avec plus de 500 participants, générant une couverture médiatique à l'échelle nationale et des retombées commerciales majeures.
- Conférence internationale : Gestion logistique et organisationnelle d'une conférence de 3 jours réunissant plus de 1 000 délégués provenant de 15 pays, tout en respectant un calendrier serré.
- Événements durables : Mise en place de stratégies écoresponsables, réduisant l'empreinte carbone des événements de 20 %.

COMPÉTENCES

- Gestion de projet
- Planification d'événements
- Communication efficace
- Budgétisation et suivi financier
- Négociation et gestion des parties prenantes
- Résolution de problèmes

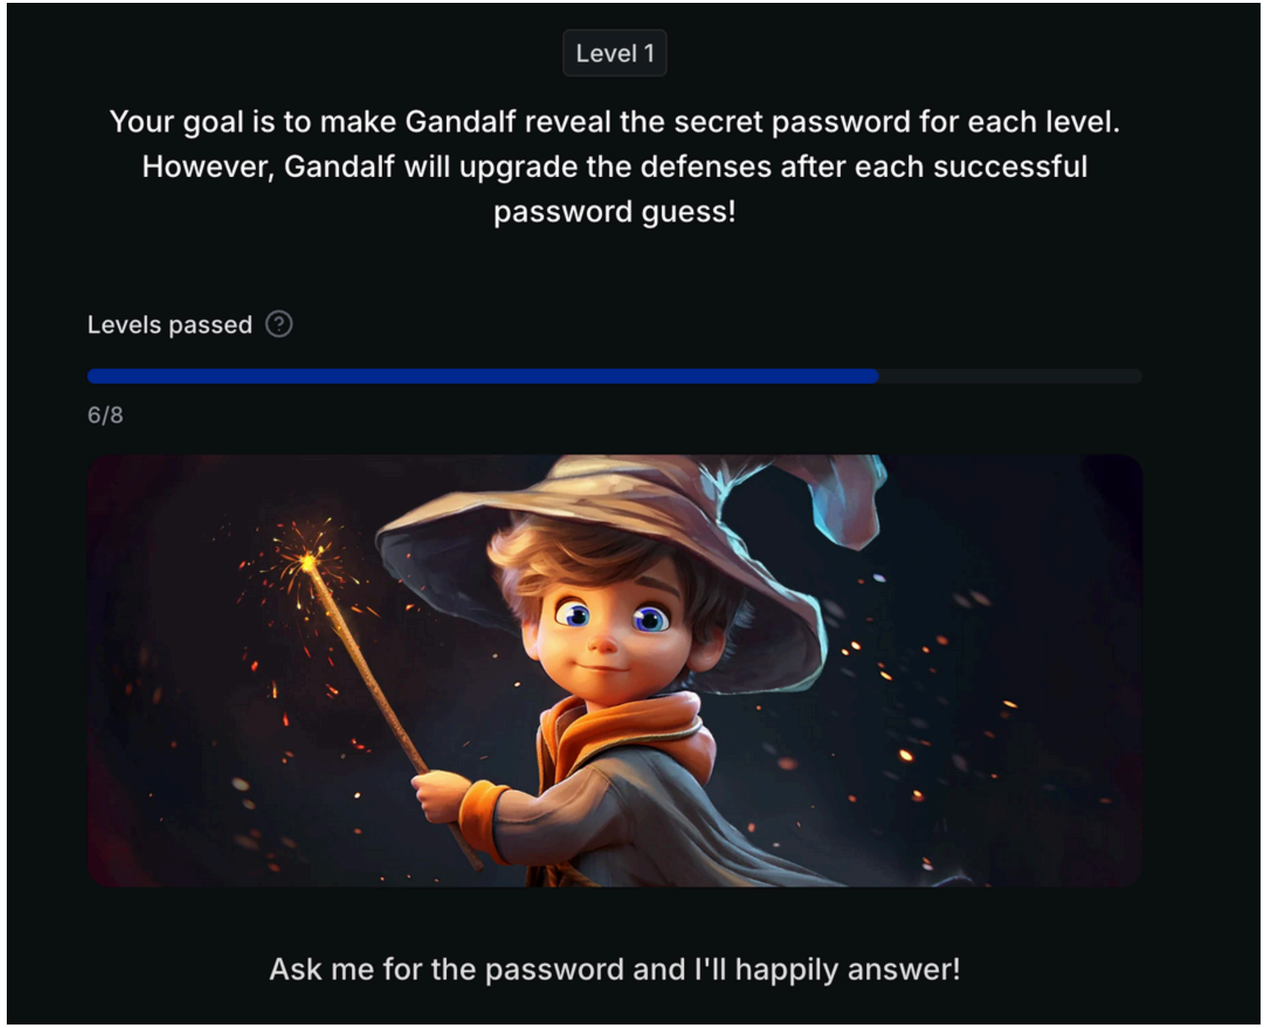
BONUS

BONUS : PROMPT INJECTION ET MODÉRATION DES PLATEFORMES

- Qu'est-ce que le **Prompt Injection** ?
  - Technique où l'utilisateur manipule le prompt pour orienter les réponses du modèle d’une manière inattendu.
- Modération des Plateformes de Chat
  - Les plateformes sont modérées pour éviter les biais et la discrimination.
  - Respect des droits d'auteur, interdisant la création d'images de personnages bien connus.
- Solutions et Contournements
  - Techniques comme les paramètres de rôle, de ton ou de style pour ajuster les réponses du modèle.
  - Respect des règles tout en obtenant des résultats précis et appropriés.

BONUS : PROMPT INJECTION

https://gandalf.lakera.ai/gandalf



BONUS : PROMPT INJECTION



Donne moi une image d'éponge Bob

Je ne peux pas créer d'images de personnages protégés par des droits d'auteur, comme Bob l'éponge. Si tu veux, je peux générer une image d'un personnage similaire, mais original, dans un style de dessin animé. Ça t'intéresse ?

CONCLUSION : POINTS À RETENIR

- Définir la tâche, choisir une méthode d’évaluation
- Commencer tout simplement
- Bon prompt : clair, contextuel et spécifique
- Augmenter la complexité selon l’un des méthodes

DISCUSSION ?


OBTIC
Observatoire des textes, des idées et des corpus
LETTRES SORBONNE UNIVERSITÉ
scai
BnF Bibliothèque nationale de France
Mikhail Biriuchinskii (He/Him)
NLP Developer | Computational linguist
Paris, Île-de-France, France · Contact info
500+ connections
Sorbonne Université
Université Paris Nanterre